

基于 3DGS 与 AIGC 的多源资产生成与真实场景融合

深度学习与空间智能期末作业 Task 1

摘要

本项目完成了一个全链路 3D 视觉系统：首先使用 COLMAP 与 3D Gaussian Splatting (3DGS) 从真实多视角图像重建物体 A；随后分别使用 threestudio 的文本到 3D 生成和 Zero123 单图到 3D 生成得到物体 B 与物体 C；最后选择 Mip-NeRF 360 的 garden 场景作为背景，通过 3DGS 重建并将 ABC 三个资产插入同一世界坐标系，输出多视角环绕渲染视频。最终融合采用“garden + A”的显式高斯渲染与 B/C mesh 深度合成的混合表达方式，使生成资产和真实背景在相机环绕时保持相对静止。

1 项目链接

GitHub: github.com/jiangjingshuang2-stack/Deep-Learning-Final。

模型权重: Google Drive 模型权重文件夹。

主要结果视频: [videos/final_ABC_garden_world_static_v2.mp4](#)。

2 任务背景

题目要求同时覆盖真实世界三维重建、AIGC 三维资产生成和真实场景融合渲染。3DGS 将场景表示为大量带颜色、不透明度、尺度和旋转的三维高斯，具有训练速度快、实时渲染质量高的优点；AIGC 资产通常以隐式场或 mesh 形式输出，和 3DGS 的显式高斯表达不同，因此最终融合的核心问题是坐标、尺度、表达形式和可见性关系的统一。

3 数据集与资产

物体 A 使用真实物体多视角图像。输入图像先顺时针旋转 90 度，再使用 COLMAP 完成特征提取、匹配和稀疏重建。经过 relaxed full-frame pinhole 设置后，得到 71 张有效相机位姿，并训练 3DGS 至 7000 iterations。

物体 B 使用 threestudio 的 DreamFusion/SDS 路径，仅输入文本 prompt：

a small blue ceramic dragon statue, detailed scales, glossy surface, studio lighting

中文含义为：一个小型蓝色陶瓷龙雕像，具有细致的鳞片、光滑有光泽的表面，工作室灯光。

物体 C 使用单张去背景后的防晒霜图片，结合 Zero123 的新视角先验完成单图到 3D 生成。

背景场景选择 Mip-NeRF 360 数据集中的 garden，并使用 3DGS 训练至 30000 iterations。

4 方法

4.1 真实多视角物体 A 的 3DGS 重建

首先使用 COLMAP 从多视角图像中恢复相机内外参和稀疏点云，再用 3DGS 优化每个高斯的均值、协方差、球谐颜色和透明度。训练目标为图像重建损失，主要由 L1 颜色项和结构相似性项组成：

$$\mathcal{L} = (1 - \lambda)\mathcal{L}_1 + \lambda\mathcal{L}_{D-SSIM}. \quad (1)$$

为了增加有效位姿数量，使用了更宽松的匹配和 full-frame pinhole 相机设置。

4.2 文本到 3D 物体 B

物体 B 使用 SDS loss 将 2D 扩散模型的先验蒸馏到三维表示中。每次从当前三维表示随机渲染视角图像，再由扩散模型估计噪声残差并反向优化三维参数。该方法的优点是只需要文本，缺点是几何约束弱，细节和多视角一致性依赖扩散先验。

4.3 单图到 3D 物体 C

物体 C 使用 Zero123 从单张输入图像预测其他视角的一致外观，再在 threestudio 中优化出三维模型。与文本到 3D 相比，单图输入提供了更强的外观约束，因此纹理和主体类别更稳定，但背面和不可见区域仍依赖模型补全。

4.4 背景 garden 的 3DGS 重建

garden 场景直接使用开源多视角数据训练 3DGS。相比物体级重建，garden 的相机轨迹、遮挡和深度范围更复杂，但多视角覆盖充分，因此最终能提供稳定的真实环境背景。

4.5 表达统一与最终融合

本项目最终采用混合表达而不是简单贴图。garden 和 A 均为 3DGS，因此先将 A 的高斯点云进行过滤、尺度归一化、坐标变换，并插入 garden 的世界坐标系；B 和 C 从 threestudio 导出为带纹理 mesh，经过归一化、Z-up 到相机/世界坐标的转换后，固定到同一 garden 世界坐标中。渲染时先使用官方 3DGS renderer 输出 garden + A 帧，再使用同一相机轨迹对 B/C mesh 做深度合成。这样 ABC 与背景在环绕视频中保持世界静止关系。

5 实验设置

6 实验结果

7 对比分析

从结果看，多视角重建最适合需要真实几何和真实纹理的资产；文本到 3D 更适合快速生成概念资产，但在本任务中 B 的龙形态在单独渲染时更明显，放入复杂背景后受尺度、视角和遮挡影响，识别性下降；单图到 3D 的 C 在正面纹理上最稳定，但背面几何不如多视角重建。

表 1: 主要实验配置

资产	方法	训练步数	输入	输出表达
A	COLMAP + 3DGS	7000	71 张有效多视角图像	Gaussian PLY
B	DreamFusion / SDS	5000	文本 prompt	textured mesh
C	Zero123	600	单张去背景图片	textured mesh
garden	3DGS	30000	Mip-NeRF 360 garden	Gaussian PLY

表 2: 超参数与日志信息

项目	Optimizer / Loss	关键超参数	日志
A 3DGS	Adam, L1 + D-SSIM	iter=7000, GPU=2	objectA_3dgs_train_7000.log
B SDS	Adam, SDS loss	steps=5000, GPU=3	W&B run 7txhb0k5
C Zero123	Adam, Zero123 guidance	steps=600, GPU=0	W&B run 4azkmnu1
garden 3DGS	Adam, L1 + D-SSIM	iter=30000, GPU=2	garden_3dgs_train_30k...log

8 现象与问题分析

Object A 的主要难点是透明背景图像导致特征匹配不足，初始 COLMAP 只有较少有效位姿。通过放宽匹配和相机模型设置，有效位姿提升到 71 张。最终融合时 A 曾出现位置偏低，底部被 garden 桌面遮挡，因此 v2 版本沿相机上方向略微上移。

Object B 的问题主要来自生成模型与最终场景尺度的差异。单独渲染时相机围绕 B 旋转，龙形状更容易被观察；放入 garden 后，相机轨迹由背景决定，B 的局部细节在远景下变小，因此需要在最终融合中调整比例、朝向和位置。最终版本采用世界静止合成，避免了早期“屏幕贴片”式静态叠加的问题。

9 结论

本任务完成了从真实采集、AIGC 资产生成、背景重建到最终融合渲染的完整流程。最终交付包括四个单独渲染视频、一个 ABC+garden 世界静止融合视频、训练日志、融合代码和中英文 LaTeX 报告源码。实验表明，3DGS 对真实场景与真实物体重建具有较高保真度，而 AIGC 资产更依赖生成先验；在融合阶段，统一坐标系、尺度和可见性关系比单独资产质量更关键。

表 3: 更详细的网络、训练与评价设置

项目	Network Architecture	Batch Size	Learning Rate	Epochs/Steps	评价指标
A	3D Gaussian, SH color	1 view/iter	3DGS 默认调度	7000 iter	L1, PSNR
B	threestudio NeRF/mesh export	1 view/iter	threestudio 默认 Adam	5000 steps	SDS loss,
C	Zero123 guidance + 3D field	1 view/iter	threestudio 默认 Adam	600 steps	guidance l
garden	3D Gaussian, SH color	1 view/iter	3DGS 默认调度	30000 iter	L1, PSNR

表 4: 关键评价指标

项目	Split	L1 ↓	PSNR ↑
A 3DGS	test @ 7000	0.00943	25.97
A 3DGS	train @ 7000	0.00478	31.81
garden 3DGS	train @ 30000	0.02038	30.04
C Zero123	train @ 600	2.30	—




图 1: 最终 v2 融合视频的多视角抽帧。ABC 与 garden 固定在同一世界坐标系中，相机环绕时物体与背景保持相对静止。




图 2: 由保存日志解析得到的训练曲线。B 的控制台日志未保存标量 loss，完整标量以 W&B run 为准。




图 3: 验证/评价指标曲线。Object A 含 train/test 的 L1 与 PSNR, garden 日志记录 train L1 与 PSNR。B/C 的生成式资产主要以 W&B 中的 guidance loss 与导出渲染进行检查。



图 4: 融合位置调试。最终 v2 将 A 略微上移, 减少被桌面遮挡的问题。

表 5: 三种资产生成方式对比

方式	几何准确度	纹理细节	计算耗时与稳定性
多视角重建 A	最高, 依赖 COLMAP 位姿	保留真实纹理, 但受拍摄质量影响	位姿提取和 3DGS 训练成
文本生成 B	类别和轮廓由扩散先验决定	风格化强, 可能缺少真实细节	只需 prompt, 但形状稳定
单图生成 C	正面准确, 背面需补全	输入视角纹理较可靠	成本较低, 受单图质量影